

1. Fuente de datos

Los datos provienen de la plataforma Roboflow Universe, y se distribuyen bajo el formato de código abierto (Open Source Dataset).

El conjunto de datos fue compilado por el usuario "SiaBar", con el objetivo de facilitar el desarrollo de sistemas automatizados de monitoreo que aseguren el cumplimiento de protocolos de seguridad en entornos industriales y de construcción.

Las imágenes se recolectaron de diversas fuentes, enfocándose en capturar una variedad de entornos, condiciones de iluminación y ángulos.

2. Cantidad de muestras

El dataset está compuesto por un total de 1,604 imágenes centradas en equipos de seguridad laboral.

Este volumen es una base sólida y totalmente adecuada para entrenar un prototipo inicial o prueba de concepto que permita comparar las arquitecturas estipuladas en el Hito 1.

3. Distribución de clases

El dataset abarca 8 categorías principales (clases) que han sido etiquetadas utilizando cajas delimitadas

Las clases incluidas son: Helmet (casco), Vest (chaleco reflectante), Glass (lentes de seguridad), Glove (guantes), Person (persona), Boots (botas de seguridad), Mask (mascarillas respiratorias) y Ear-protection (protección auditiva).

La clase *Person* incluye tanto a individuos que están utilizando el equipo como a los que no, lo cual está pensado para mejorar la detección de personas en conjunto con el reconocimiento de EPP.

4. Calidad de datos

La colección se describe como una base de datos diversa, específicamente orientada a entornos industriales y de construcción.

Cada una de las clases ha sido anotada meticulosamente para entregar cajas delimitadoras precisas, asegurando así que los datos tengan la alta calidad requerida para el entrenamiento de modelos de aprendizaje automático.

5. Limitaciones

Ausencia de clases negativas explícitas: A diferencia de otros datasets, este solo etiqueta el equipo presente y a la persona. Como no tiene clases como "NO-Helmet" o "NO-Vest", la detección de infracciones recaerá en la arquitectura de software (por ejemplo, programar el backend para cruzar datos y alertar si detecta la clase *Person* pero la caja delimitadora no intersecta con una clase *Helmet*).

Ruido por clases innecesarias: El dataset incluye protección auditiva, mascarillas y botas. Como nuestra constructora limitó la política a casco, chaleco, lentes y guantes en el Hito 1, estas clases adicionales consumirán recursos de inferencia.

Volumen de datos moderado: Aunque 1,604 imágenes son un gran inicio, en un escenario real es un número que puede propiciar el sobreajuste (*overfitting*).

Será estrictamente necesario aplicar técnicas de aumento de datos (*Data Augmentation*) para robustecer el modelo.

Link del dataset: <https://universe.roboflow.com/siabar/ppe-dataset-for-workplace-safety>